

DỰ ÁN HỌC MÁY TỪ ĐẦU ĐẾN CUỐI

Chương 2 - End-to-End Machine Learning Project

TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026



Nội dung Chương trình

1

1. Giới thiệu Dự án & Khởi tạo Dữ liệu

2

2. Khám phá & Chuẩn bị Dữ liệu

3

3. Chọn, Huấn luyện, Tinh chỉnh & Triển khai

Mục tiêu bài học



- ✓ Hiểu rõ toàn bộ quy trình phát triển một dự án học máy thực tế từ khi bắt đầu đến khi triển khai.
- ✓ Thực hành các kỹ thuật chuẩn bị, làm sạch, và biến đổi dữ liệu.
- ✓ Trực quan hóa dữ liệu để tìm ra các mẫu (patterns) và tương quan.
- ✓ Xây dựng pipeline dữ liệu chuẩn.
- ✓ Đánh giá, tinh chỉnh và lựa chọn mô hình học máy tốt nhất.




1. Giới thiệu Dự án & Khởi tạo Dữ liệu

Làm việc với dữ liệu thực



Học máy tốt nhất là thực hành trên dữ liệu thực. Trong chương này, chúng ta sử dụng tập dữ liệu **Nhà ở California (California Housing Prices)**.

Mục tiêu: Dự đoán giá nhà trung bình tại một khu vực bất kỳ ở California dựa trên các đặc trưng như dân số, thu nhập trung bình, v.v.



Hình 2-1. Giá nhà California


Nhìn vào bức tranh lớn: Xác định vấn đề



Trước khi phân tích, cần hiểu mục đích kinh doanh là gì? Mô hình này sẽ được sử dụng như thế nào? Việc hiểu mục đích sẽ giúp quyết định: Thuật toán nào? Thước đo hiệu suất nào? Mức độ đầu tư công sức?

Bài toán của chúng ta: Hệ thống nhận dữ liệu khu vực và dự đoán giá nhà. Đầu ra này sẽ được đưa vào một hệ thống máy học khác để quyết định có nên đầu tư vào khu vực đó hay không.

Pipeline hệ thống học máy



Hình 2-2. Một pipeline máy học cho đầu tư bất động sản

Chọn một Thước đo Hiệu suất



Vì đây là bài toán hồi quy (Regression), chúng ta sử dụng **Căn bậc hai Sai số Toàn phương Trung bình (RMSE - Root Mean Square Error)**.

RMSE cho biết sai số dự đoán điển hình. Càng nhỏ càng tốt.

Công thức 2-1. Sai số toàn phương trung bình (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2}$$

Nếu dữ liệu có nhiều ngoại lai (outliers), ta có thể sử dụng **Sai số Tuyệt đối Trung bình (MAE - Mean Absolute Error)**.

Công thức 2-2. Sai số tuyệt đối trung bình (MAE):

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |h(x^{(i)}) - y^{(i)}|$$

Kiểm tra các Giả định



Luôn liệt kê và xác minh các giả định đã đặt ra.

Ví dụ: Hệ thống hạ nguồn có thực sự cần dự đoán giá trị cụ thể, hay chỉ cần các hạng mục (rẻ, trung bình, đắt)?



Nếu họ chỉ cần hạng mục, thì chúng ta nên cấu trúc nó thành bài toán Phân loại (Classification) thay vì Hồi quy.



Lấy Dữ liệu & Môi trường làm việc

Môi trường Google Colab



Chúng ta sẽ sử dụng **Google Colab** - một môi trường Jupyter Notebook miễn phí trên đám mây.




Không cần cài đặt phần mềm phức tạp trên máy tính cá nhân.




Cung cấp GPU/TPU miễn phí để huấn luyện mô hình.

Minh họa: Môi trường Google Colab



Hình 2-3. Giao diện Google Colab



Hình 2-4. Chạy code trên Colab

Tải và Xem dữ liệu



	longitude	latitude	housing_median_age	median_income	ocean_proximity	median_house_value
0	-122.23	37.88	41.0	8.3252	NEAR BAY	452600.0
1	-122.22	37.86	21.0	8.3014	NEAR BAY	358500.0
2	-122.24	37.85	52.0	7.2574	NEAR BAY	352100.0
3	-122.25	37.85	52.0	5.6431	NEAR BAY	341300.0
4	-122.25	37.85	52.0	3.8462	NEAR BAY	342200.0

Hình 2-6. Năm hàng đầu tiên trong tập dữ liệu


Xem tóm tắt dữ liệu



```
housing.describe()
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
count	20640.000000	20640.000000	20640.000000	20640.000000	20433.000000	20640.000000	20640.000000	10.000000	20640.000000
mean	-119.569704	35.631861	28.639486	2635.763081	537.870553	537.870553	296.273322	2.539946	206855.816909
std	2.003532	2.135952	12.585558	2181.615522	421.385070	421.385070	292.376477	0.331326	115395.615874
min	-124.350000	32.540000	1.000000	2.000000	1.000000	1.000000	0.000000	0.000000	14999.000000
25%	-118.490000	34.260000	18.000000	1447.750000	296.000000	435.000000	100.000000	4.500000	179700.000000
75%	-118.010000	37.710000	37.000000	3148.000000	647.000000	647.000000	100.000000	7.500000	264725.000000
max	-114.310000	41.950000	52.000000	39320.000000	645.000000	6445.000000	3400.000000	52.000000	500001.000000

Hình 2-7. Tóm tắt của từng thuộc tính số



Hình 2-8. Biểu đồ tần suất (Histogram)

Tạo tập kiểm thử (Test set): Tại sao cần thiết?

Chúng ta phải tách một phần dữ liệu (khoảng 20%) ngay lập tức và **không bao giờ nhìn vào nó**.

Lý do: Tránh **thiên kiến rình mò dữ liệu (Data Snooping Bias)**.

Nếu chọn thuật toán dựa trên toàn bộ dữ liệu, mô hình có thể Overfit trên tập đó nhưng dự đoán kém trong thực tế.

