

Điểm yếu chí mạng của Cây quyết định đơn lẻ



Rất yếu ớt và Dễ bị đánh lừa!

Quá nhạy cảm: Chỉ cần thay đổi dữ liệu huấn luyện một chút xíu, cái cây đó sẽ mọc ra những nhánh hoàn toàn khác biệt.

Hậu quả: Dẫn đến một dự đoán sai lệch ngay lập tức.

Để khắc phục sự yếu ớt này, chúng ta cần một cơ chế đột phá hơn!

Giải pháp đột phá: Rừng ngẫu nhiên (Random Forest)

Từ một cây thành một khu rừng!



Thay vì phụ thuộc vào một cây quyết định **mỏng manh**,
thuật toán tập hợp hàng trăm cây lại với nhau.

1


Cơ chế 1: Bootstrap Aggregation
(Bagging)

2

Cơ chế 2: Lấy mẫu không gian
con (Subspace Sampling)

Cơ chế 1: Bootstrap Aggregation (Bagging)

Đa dạng hóa góc nhìn



- 1. Vấn đề cũ:** Nếu đưa toàn bộ dữ liệu cho tất cả các cây cùng học, chúng sẽ học giống hệt nhau.
- 2. Cách lấy mẫu:** Thuật toán bốc ngẫu nhiên một phần dữ liệu cho một cây -> Rồi lại thả vào rổ, bốc tiếp một phần khác cho cây tiếp theo.
- 3. Kết quả:** Mỗi cây sẽ được huấn luyện trên một tập dữ liệu hơi khác nhau.

Cơ chế 2: Lấy mẫu không gian con (Subspace Sampling)

Ẩn dụ: 100 Bác sĩ Hội chẩn

Giả sử bạn nhờ 100 bác sĩ hội chẩn cho một ca bệnh phức tạp.



Nếu đưa cùng 1 bộ hồ sơ bệnh án đầy đủ y hệt nhau cho 100 người.
Tất cả đều sẽ chỉ chăm chăm nhìn vào triệu chứng rõ nhất (ví dụ: ho dữ dội).
Hệ quả: Cả 100 bác sĩ đều kết luận ra cùng một căn bệnh, thiếu đi sự khách quan!

Giải pháp: “Giấu bệnh án” để ép Tư duy Độc lập

Làm thế nào để ép các bác sĩ suy nghĩ khác biệt? Lấy mẫu không gian con hoạt động y như việc chúng ta cố tình giấu đi một vài kết quả xét nghiệm khi đưa cho từng người.



Bác sĩ A không được xem X-quang.



Bác sĩ B bị giấu chỉ số huyết áp.

Khá khắc nghiệt, nhưng vô tình ép các bác sĩ (các cây quyết định) phải suy nghĩ thực sự độc lập. Họ buộc phải đào sâu tìm dấu hiệu bệnh lý từ các triệu chứng nhỏ nhất, mờ nhạt hơn.

Sức mạnh của Đám đông (Wisdom of the Crowd)



1. Tập hợp: Khi tập hợp
chẩn đoán của 100 bác
sĩ với 100 góc nhìn hoàn
toàn độc lập đó lại.



2. Quyết định: Rồi lấy
bầu chọn số đông
(Majority Vote).



3. Kết quả tối thượng:
Chúng ta sẽ có một kết
quả dự đoán chính xác và
ổn định hơn gấp nhiều
lần so với một cây duy
nhất!

Vấn đề: Dữ liệu Mất cân bằng

Chúng ta quên mất
một điều!



Dữ liệu của chúng ta
vẫn **cực kỳ mất cân
bằng** (Hiếm khi xảy
ra thiếu hụt).

Nếu cứ để mô hình học một cách tự nhiên từ dữ liệu,
nơi mà số lần giao thành công gấp 100 lần thiếu hụt...

Mô hình Học Máy sẽ trở nên vô cùng Lười biếng!

Căn bệnh Lười biếng của Mô hình




Quy luật “Khôn lỏi”

Mô hình nhận ra rằng: “Ồ, tôi chỉ cần nhắm mắt đoán bừa là KHÔNG BAO GIỜ THIẾU HÀNG, thì tỷ lệ chính xác (Accuracy) của tôi nghiêm nhiên vẫn đạt 99%!”

Mô hình gian lận bài thi bằng cách đánh lụi toàn bộ một đáp án.

Doanh nghiệp sẽ sụp đổ vì mô hình bỏ lọt 100% các ca thiếu hụt thực sự!



Hình: Xử lý Dữ liệu Mất cân bằng

Xử lý Lười biếng: Lấy mẫu giảm (Downsampling)




Kỹ thuật **Downsampling**:

- Thuật toán chủ động cắt bỏ bớt lượng dữ liệu khổng lồ của nhóm giao hàng thành công.
- Ép tỷ lệ xuống sao cho nhóm bình thường chỉ nhỉnh hơn một chút (1.5 lần) so với ca thiếu hụt.

Mô hình bị tước đi lợi thế về số lượng, bị dồn vào chân tường!

Mô hình buộc phải Học thật sự

Khi nhóm bình thường không còn áp đảo, đoán bừa sẽ nhận điểm 0.



Mô hình buộc phải thực sự học cách nhận diện các đặc trưng ẩn giấu của những ca thiếu hụt thay vì chỉ gian lận.

Tại sao Accuracy trở nên vô nghĩa?



Trong mô hình rủi ro (đứt gãy chuỗi cung ứng, gian lận thẻ tín dụng),
Độ chính xác tổng thể (Accuracy) là vô nghĩa.

Chúng ta cần một **bảng điểm đánh giá năng lực** khác hơn:

1. **Độ nhạy (Sensitivity).**
2. **Độ đặc hiệu (Specificity).**

Đánh giá mới: Độ nhạy (Sensitivity)

Khả năng Bắt đúng bệnh



Sensitivity (True Positive Rate): Khả năng mô hình "đánh hơi" trúng phóc những ca thực sự bị thiếu hụt hàng hóa.

Nếu **độ nhạy thấp**, mô hình sẽ **bỏ lọt tội phạm**, không cảnh báo được rủi ro đứt gãy.

Đánh giá mới: Độ đặc hiệu (Specificity)


Khả năng Không báo động nhầm



Specificity (True Negative Rate): Khả năng mô hình không đưa ra những báo động giả đối với các đơn hàng đang giao suôn sẻ.

Nếu **độ đặc hiệu thấp**, mô hình sẽ **gào thét** báo động liên tục, khiến doanh nghiệp hoang mang và tốn kém chi phí dự phòng vô ích.

Bảng điểm thực sự: Đường cong ROC & AUC



Làm sao để biết mô hình có tốt không?

Đường cong ROC (Receiver Operating Characteristic): Vẽ Độ nhạy đối chiếu với (1 - Độ đặc hiệu).

Chỉ số AUC (Area Under the Curve): Điểm số từ 0 đến 1. AUC càng gần 1, mô hình càng xuất sắc trong việc phân loại thực sự thay vì nhầm lẫn đoán bừa.

Ưu điểm tuyệt vời của Rừng Ngẫu Nhiên



Rất dễ tính:

Không bắt chúng ta phải chuẩn hóa dữ liệu quá cầu kỳ.



Chống nhiễu tốt: Tự động phát lờ đi những biến số ngoại lai nhiễu loạn (Outliers).



Kháng Đa cộng tuyến:

Xử lý rất mượt hiện tượng các biến đầu vào tác động qua lại lẫn nhau.

⇒ Cứu cánh hoàn hảo cho môi trường hỗn loạn như chuỗi cung ứng!