


3.7 Đặc trưng 4 Chữ V của Dữ liệu Lớn (IBM)

- **1. Volume (Khối lượng):** Kích thước khổng lồ của dữ liệu.
- **2. Velocity (Vận tốc):** Tốc độ dữ liệu được tạo ra liên tục (Thời gian thực - Real-time).
- **3. Variety (Đa dạng):** Các loại dữ liệu từ có cấu trúc (bảng biểu) đến phi cấu trúc (văn bản, âm thanh, hình ảnh).
- **4. Veracity (Tính Xác thực/Độ Tin cậy):** Chất lượng dữ liệu có bị nhiễu, sai sót, hay mơ hồ đối với phân tích không.

4.1 Vòng đời Dự án Khoa học Dữ liệu

- **Định nghĩa Vấn đề**
- **Thu thập Dữ liệu** (Data Ingestion & Storage)
- **Chuẩn bị Dữ liệu** (Làm sạch & Khám phá EDA)
- **Mô hình hóa** (Train & Test)
- **Đánh giá Mô hình**
- **Thử nghiệm (Experimentation)** và Triển khai



Hình 2.3: Vòng đời Dự án Khoa học Dữ liệu

4.2 Bước 1: Định nghĩa Vấn đề (Ví dụ: Nợ quá hạn)

- Cần trả lời các câu hỏi nền tảng:
 - Vấn đề kinh doanh là gì? (Giảm tỷ lệ nợ quá hạn vay tiêu dùng)
 - Dữ liệu nào cần thiết? (Lịch sử thanh toán, số dư tài khoản, độ tuổi khách hàng)
 - Định nghĩa sự thành công (KPI) ra sao? (Giảm 10% nợ xấu)
- Việc cấu trúc bài toán tốt ngay từ đầu quyết định toàn bộ sự thành công của dự án khoa học dữ liệu.

4.3 Bước 2: Thu thập & Phân loại Dữ liệu

- **Dữ liệu có cấu trúc:** Dạng bảng, SQL, hàng/cột rõ ràng.
- **Bán cấu trúc:** JSON, XML, file Log hệ thống.
- **Phi cấu trúc:** Hình ảnh (hóa đơn), âm thanh, video, văn bản tự do.

Structured Data	Semi-structured Data	Unstructured Data	
Definition	Data that can be stored in relational databases (such as SQL tables) with rows and columns. They have a relational key and can be easily mapped into pre-designed fields.	Data that is not stored in relational databases but has some organizational properties that make it easier to analyze	All other data that has no organizational structure
Examples	Databases (tables with customer names, dates, addresses, and other data), CRM systems, ERP systems, and census records	Email messages, tweets, data contained on web pages within HTML tags, XML, JSON, and CSV	Audio, images, videos, text

Hình 2.4: Phân loại Cấu trúc Dữ liệu

4.4 Bước 3: Chuẩn bị Dữ liệu (Data Preparation)

- **Dữ liệu thô (Raw data)** thường lộn xộn, thiếu sót và chứa lỗi (Giá trị NULL, trùng lặp).
- **Kiểm tra chất lượng dữ liệu (Data Quality Checks - QC):**
 - 1 **Tính đầy đủ (Completeness):** Không bị thiếu cột, thiếu trường giá trị.
 - 2 **Tính chính xác (Accuracy):** Loại bỏ hoặc xử lý giá trị bất thường (Outliers).
 - 3 **Tính duy nhất (Uniqueness):** Khử trùng lặp (De-duplicate) theo Khóa chính (Ví dụ: ID khách hàng).
 - 4 **Tính nhất quán (Consistency):** Logic giữa các trường dữ liệu hợp lý.
 - 5 **Tính hợp lệ (Validity):** Chuẩn hóa định dạng (Ngày tháng, Text).

4.5 Phân tích Dữ liệu Khám phá (EDA)

- **Exploratory Data Analysis (EDA):**

- Là bước tạo các thống kê mô tả (Mean, Median, Mode) và vẽ biểu đồ để tìm ra quy luật (patterns) tiềm ẩn của dữ liệu trước khi chạy thuật toán.
- Phân tích đơn biến (Univariate) và song biến (Bivariate).

- **Nhận diện Biến Mục tiêu (Target Variable):**

- Biến kết quả kinh doanh mà ta muốn mô hình dự đoán.
- Ví dụ bài toán phân loại nhị phân: Biến mục tiêu là trạng thái Nợ quá hạn (1) hoặc Không nợ quá hạn (0).

4.6 Phân loại Mô hình Học máy


- **1. Học có giám sát (Supervised Learning):** Dữ liệu đã có "Nhãn mục tiêu" (Target).
 - **Phân loại (Classification):** Dự báo danh mục rời rạc (Ví dụ: Nợ xấu / An toàn, Thư rác / Bình thường).
 - **Hồi quy (Regression):** Dự báo số liên tục (Ví dụ: Dự báo Giá nhà, Doanh thu).
- **2. Học không giám sát (Unsupervised Learning):** Tìm cấu trúc ngầm trên dữ liệu KHÔNG có mục tiêu (Không Nhãn).
 - **Phân cụm (Clustering):** Gom nhóm đối tượng tương tự nhau (Phân khúc KH).
 - **Luật liên kết (Association):** Tìm quy luật (Mua bia kèm tã lót).

4.7 Lựa chọn Thuật toán (Algorithms)

- Không có mô hình học máy nào hoàn hảo. Lựa chọn phụ thuộc vào bài toán.
- **Mô hình Tuyến tính (Linear / Logistic Regression):**
 - Đơn giản, tốc độ chạy nhanh, cực kỳ dễ diễn giải (Explainable). Phù hợp ứng dụng công nghiệp và kiểm toán.
- **Mô hình Phi tuyến tính (Decision Trees, SVM, Neural Networks):**
 - Cực mạnh, hiệu suất dự đoán cao cho dữ liệu thực tế phức tạp.
 - Nhược điểm: Tính chất "Hộp đen" (Black box), khó giải trình logic đằng sau kết quả.

4.8 Quy trình Xây dựng Mô hình (Modeling Process)

- **Chia dữ liệu (Data Split):** Thường tỷ lệ 80% (Huấn luyện) / 20% (Xác thực).
- **Train (Huấn luyện):** Dạy thuật toán nhận diện quy luật.
- **Validate (Xác thực):** Đánh giá lỗi và tinh chỉnh (Tuning) tham số mô hình.
- **Test (Kiểm thử):** Chạy trên tập dữ liệu kiểm thử (Test dataset) mới hoàn toàn để đo lường hiệu suất thực tế (chưa từng tiếp xúc trước đó).




Hình 2.5: Quy trình Mô hình hóa

4.9 Đánh giá Mô hình (Model Evaluation)

- Phân tích lỗi (Error Analysis) là bắt buộc.
- **Bài toán Phân loại:** Sử dụng **Ma trận nhầm lẫn (Confusion Matrix)** so sánh dự đoán Đúng/Sai với mục tiêu thực.
 - Các chỉ số: *Accuracy* (Độ chính xác chung), *Precision* (Độ chính xác dương), *Recall* (Độ bao phủ/Độ nhạy).
- **Bài toán Hồi quy:** Tính độ lệch giữa dự báo số và thực tế.
 - Các chỉ số: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error).

4.10 Phân tích Lỗi: Độ lệch (Bias) & Phương sai (Variance)


- **Lỗi không thể khử (Irreducible Error):** Sai số nhiều không thể tránh (Bayes error).
- **Độ lệch (Bias):** Lỗi do giả định mô hình sai (Underfitting). Mô hình luôn "chệch" một khoảng cách lớn so với mục tiêu thực sự ở tâm (Tâm bia).
- **Phương sai (Variance):** Lỗi do mô hình ghi nhớ cả dữ liệu nhiễu (Overfitting). Sự phân tán rộng của các điểm dự đoán.



Hình 2.6: Mô phỏng Bias & Variance

4.11 Ngăn xếp Công nghệ Big Data (Technology Stack)

- **Công cụ Đưa Dữ liệu vào (Ingestion):**
 - **Apache Kafka:** Dòng dữ liệu thời gian thực (Streaming), ví dụ Giao dịch chứng khoán (HFT).
 - **Sqoop / Flume:** Chuyển lô dữ liệu từ CSDL truyền thống (RDBMS).
- **Công cụ Xử lý Dữ liệu:** Spark, Pandas, SQL.



Hình 2.7: Công nghệ Dữ liệu lớn

4.12 Lưu trữ Dữ liệu: Data Warehouse vs. Data Lake

- **Kho Dữ liệu (Data Warehouse):**

- Kho lưu trữ tập trung, dữ liệu có cấu trúc chặt chẽ, phải tuân theo lược đồ bảng định trước (Schema).
- Dữ liệu kém chất lượng bị loại bỏ. Tối ưu cho truy vấn, báo cáo tài chính ổn định.

- **Hồ Dữ liệu (Data Lake):**

- Triết lý: "**Lưu trữ trước, xử lý sau**".
- Giữ dữ liệu ở định dạng Thô (Raw) kể cả ảnh, text.
- Tối ưu về tính linh hoạt và tiết kiệm chi phí, sử dụng HDFS (Hệ thống tệp phân tán Hadoop). Rất phù hợp cho AI/ML nghiên cứu.

4.13 Thách thức Quản trị trong Dự án Dữ liệu (P1)

- Khoa học Dữ liệu cần thiết phải có chiến lược quản trị rủi ro rõ ràng.
- **Quyền riêng tư (Privacy) & Bảo mật (Security):**
 - Quản lý quyền truy cập dữ liệu nhạy cảm theo cấp bậc (Ví dụ: Ai được xem lương, lịch sử y tế?).
 - Tuân thủ quy định bảo vệ dữ liệu (GDPR Châu Âu, Luật An ninh Mạng VN). Kỹ thuật: Ẩn danh hóa (Anonymization).
- **Đạo đức AI (Ethics):**
 - Đảm bảo thuật toán không bị thiên vị (Bias) và phân biệt đối xử (Ví dụ: Chấm điểm tín dụng không dựa trên giới tính, chủng tộc).

4.14 Thách thức Quản trị trong Dự án Dữ liệu (P2)

- **Thiếu sự tài trợ (Lack of sponsorships):**

- Chi phí ban đầu xây dựng kho dữ liệu và tuyển dụng đội ngũ Data Scientist rất tốn kém (Setup cost).

- **Khó khăn khi Triển khai (Deployment):**

- Rất nhiều mô hình AI thành công trên môi trường thử nghiệm nhưng "chết yểu" khi phải tích hợp (Scale) với các hệ thống kế toán cũ (Legacy Systems).

- **Quản trị Kỳ vọng (Expectation Management):**

- AI không phải là "Phép thuật". Nó chỉ là công cụ giảm thiểu sự kém hiệu quả và cần thời gian dài để cải thiện độ chính xác.