

Làm thế nào mà thuật toán k-Means biết hai khách hàng có "hành vi giống nhau" để xếp chung vào một cụm?

Chúng ta cùng tìm hiểu phần tiếp theo!

Thuật toán k-Means: Cơ chế Đo khoảng cách

Khoảng cách (Distance) trong toán học:

- Thuật toán k-Means sử dụng "khoảng cách" để đo lường sự tương đồng giữa các khách hàng.
- Hãy tưởng tượng mỗi người khách là một điểm trên trục tọa độ.

Khoảng cách ngắn = Hành vi giống nhau

- Điểm A (Khách 1) và Điểm B (Khách 2) nằm sát nhau.
- Đoạn thẳng nối hai điểm đó càng ngắn, tức là hành vi tiêu dùng (ví dụ số tiền chi, số lần mua) của hai người đó càng giống nhau.
- K-Means luôn cố gắng gom những người "đứng gần nhau" vào cùng một cụm.

Ví dụ trực quan: Bữa tiệc khổng lồ & lộn xộn

Bước 1: Chọn số lượng bàn (k)

- Hãy tưởng tượng bạn đang tổ chức một bữa tiệc khổng lồ.
- Ban đầu, bạn chọn một số lượng bàn tiệc nhất định, gọi là k .
- Bạn đặt ngẫu nhiên k chiếc bàn giữa căn phòng lộn xộn. (Các chiếc bàn này đại diện cho các **tâm cụm - Centroid**).

Ví dụ trực quan: Bữa tiệc khổng lồ & lộn xộn (Tiếp)

Bước 2: Gán điểm (Assign)

- Các khách mời (đại diện cho Dữ liệu khách hàng) tiến vào phòng.
- Họ sẽ tự động nhìn quanh và chạy đến chiếc bàn nào **gần họ nhất**.
- Lúc này, khách đã "bu quanh" các bàn.

Bước 3: Dời tâm (Update)

- Bạn nhận ra: Chiếc bàn lúc này bị lệch, nó không còn nằm ở chính giữa nhóm khách đang bu quanh nó nữa.
- Thế là bạn hì hục khiêng chiếc bàn dời vào đúng **trung tâm (trọng tâm)** của nhóm khách đó.

Ví dụ trực quan: Bữa tiệc khổng lồ & lộn xộn (Tiếp)

Bước 4: Sự thay đổi & Hội tụ

- Khi bạn dời bàn, một số người ở rìa bất ngờ thấy: *"Ô, cái bàn nhóm khác giờ lại gần mình hơn cái bàn hiện tại!"*
- Họ liền chạy sang nhóm khác.
- Bạn lại phải tiếp tục dời bàn.
- **Điểm Hội tụ:** Lặp đi lặp lại quy trình này cho đến khi không còn khách nào muốn chuyển bàn nữa (Trạng thái ổn định nhất).

Cấu trúc Lặp của k-Means (Tóm tắt)

Quy trình thuật toán (Vòng lặp tối ưu)

- ➊ **Khởi tạo:** Chọn ngẫu nhiên k tâm cụm ban đầu.
- ➋ **Bước Gán (Assignment):** Gán mỗi điểm dữ liệu vào tâm cụm gần nhất.
- ➌ **Bước Cập nhật (Update):** Tính toán lại vị trí tâm cụm mới dựa trên trung bình cộng của các điểm trong cụm.
- ➍ **Kiểm tra:** Lặp lại Bước 2 và Bước 3 cho đến khi vị trí các tâm cụm không thay đổi.

Nhược điểm cực lớn: Nhạy cảm với Điểm ngoại lai (Outliers)

- Tâm cụm của k-Means được tính bằng **Trung bình cộng (Mean)**.
- Nếu trong bữa tiệc có một "vị khách khổng lồ" đứng tuốt ngoài góc phòng, phép tính trung bình sẽ kéo lê chiếc bàn (tâm cụm) về phía góc đó một cách vô lý.

Tại sao Dữ liệu Kế toán lại nhiều Outliers?

- Trong tài chính kế toán, dữ liệu thường bị lệch (skewed).
- Đa số khách hàng chi 1 triệu đồng/tháng, nhưng thỉnh thoảng có vài khách sỉ chi tới 500 triệu đồng/tháng.
- Các khách hàng "đột biến" này sẽ phá hỏng mô hình k-Means thông thường.

Chống nhiễu (Robust) tốt hơn k-Means!

- **Khác biệt lỗi:** Thay vì dùng giá trị "Trung bình cộng" (vô hình) làm tâm, k-Medoid sử dụng một **điểm dữ liệu thực tế** (Medoid) để làm tâm.
- Giống như việc bạn chọn ra một vị khách tiêu biểu nhất trong nhóm làm "trưởng bàn", và lấy vị trí của người đó làm tâm cụm.
- Trưởng bàn là người thực, nên không bị kéo lê bởi một vài cá nhân cực đoan bên ngoài.

Làm sao biết k bằng bao nhiêu?

Một câu hỏi kinh điển trong Machine Learning!

- Cả k-Means và k-Medoid đều **không tự biết** k bằng bao nhiêu.
- Bạn phải nói cho nó biết bạn muốn chia thành 2, 3, hay 5 nhóm.
- Nếu đoán mò số k , kết quả có thể rất tồi tệ. Ta cần một công cụ chấm điểm để tìm k tối ưu.

Hệ số Silhouette (Silhouette Width)

Công cụ đo lường chất lượng cụm

- Silhouette chấm điểm dựa trên mức độ hợp lý của việc chia nhóm.
- Dao động từ **-1 đến 1**.
- Nếu điểm số càng gần 1, chứng tỏ các cụm rất gắn kết bên trong và tách biệt rõ ràng với bên ngoài → **Lý tưởng!**

Hai tiêu chí cốt lõi của Silhouette

Cách tính điểm Silhouette

- ① **Độ gắn kết (Cohesion):** Các điểm dữ liệu trong cùng một cụm có nằm sát nhau không? (Càng sát càng tốt).
- ② **Độ tách biệt (Separation):** Hai cụm khác nhau có nằm xa nhau không? (Càng xa càng tốt để tránh nhầm lẫn).

Biến phân tích: Số tiền chi tiêu & Thời gian gắn bó.

- Thuật toán chỉ ra 2 cụm hoàn toàn trái ngược:
- **Cụm 1:** Khách gắn bó rất lâu (chậm rời bỏ) nhưng tiêu rất ít tiền.
- **Cụm 2:** Khách vừa gắn bó lâu, lại vừa chi rất nhiều tiền.
- **Hành động Kế toán Quản trị:** Lập tức dồn lực Marketing & Chăm sóc khách hàng vào Cụm 2 để tối ưu hóa ROI (Tỷ suất hoàn vốn).