

Học Sâu (Deep Learning)

Chương 10: Diễn dịch và Trực quan hóa Mạng Tích chập (Interpreting what ConvNets learn)

Đại học Đông Á

July 23, 2026

1. Vấn đề "Hộp Đen" trong Deep Learning
2. Trực quan hóa Biểu diễn Trung gian
3. Trực quan hóa Bộ lọc bằng Gradient Ascent
4. Bản đồ Kích hoạt Lớp (Grad-CAM)
5. Tổng kết

Deep Learning có phải là Hộp Đen (Black Box)?

- Định kiến phổ biến cho rằng Mạng nơ-ron là những chiếc "Hộp đen", không thể giải thích được lý do nó đưa ra quyết định.
- Khả năng diễn dịch (**Interpretability**) là yêu cầu bắt buộc trong các lĩnh vực rủi ro cao:
 - **Y tế:** "Tại sao AI lại chẩn đoán bệnh nhân này bị ung thư?"
 - **Xe tự lái:** "Tại sao AI lại không nhận ra chiếc xe tải phía trước?"
- Thực tế: Định kiến "Hộp đen" **KHÔNG** đúng với Mạng Tích chập (ConvNets).
- ConvNets học các biểu diễn hình ảnh không gian 2D, do đó chúng ta có thể **trực quan hóa** những gì nó đang "nhìn" thấy bằng 3 kỹ thuật cốt lõi.

Kỹ thuật 1: Trục quan hóa Bản đồ Đặc trưng (Feature Maps)

- **Mục tiêu:** Hiểu cách các lớp Tích chập liên tiếp (Successive Layers) biến đổi và bóc tách một hình ảnh đầu vào.
- **Khái niệm Kích hoạt (Activations):** Đầu ra của một lớp Tích chập (bao gồm cả chiều không gian và số kênh) được gọi là Activation.
- Mỗi kênh (Channel) trong bản đồ đặc trưng hoạt động như một bộ dò mẫu (Pattern Detector) tương đối độc lập. Do đó ta sẽ xuất hình ảnh của từng Kênh ra màn hình để phân tích.

Ví dụ Đầu vào


- Ta đưa một bức ảnh con mèo (hoàn toàn mới, không có trong tập huấn luyện) vào một mạng CNN đã được train.
- Hãy xem cách các lớp Tích chập phản ứng (Activate) với bức ảnh này.



Hình 10.1: Hình ảnh con mèo thử nghiệm

Kích hoạt của các Bộ lọc Đơn lẻ (Single Filter)


- Quan sát một kênh ở **Lớp đầu tiên** của mô hình.
- Lớp này giữ lại gần như toàn bộ thông tin không gian chi tiết của con mèo.
- Bộ lọc này đang hoạt động như một công cụ **Dò tìm Cạnh (Edge Detector)**, đặc biệt phản ứng mạnh với đôi tai mèo và mắt mèo.



Hình 10.2: Đặc trưng Kênh số 4 (Lớp Conv đầu tiên)

Kích hoạt Kênh đặc biệt (Mắt mèo)


- Một kênh khác ở cùng lớp đầu tiên lại có nhiệm vụ khác.
- Kênh số 5 này đặc biệt nhạy cảm với những **đốm sáng hình tròn** (như con ngươi của mắt mèo) và bỏ qua hầu hết các thông tin về lông hoặc cạnh tai.



Hình 10.3: Đặc trưng Kênh số 5 (Bắt dính Mắt mèo)

Trực quan hóa Toàn bộ Các Lớp Sâu (Deep Layers)

- Khi tiến sâu hơn vào mạng, các bản đồ đặc trưng trở nên **thưa thớt (Sparse)** và **trừu tượng (Abstract)**.
- Chúng không còn chứa hình dáng vật lý của con mèo nữa, mà chuyển sang lưu giữ các Khái niệm (Ví dụ: "Có tai mèo trong vùng không gian này hay không?").
- Các ô trống đen xì nghĩa là bộ lọc đó hoàn toàn không tìm thấy mẫu mà nó cần.



Kỹ thuật 2: Gradient Ascent trên Không gian Ảnh

- **Mục tiêu:** Thay vì xem Bộ lọc phản ứng với ảnh thật như thế nào, ta hãy **tự tạo ra một bức ảnh ảo** (từ mảng nhiễu trắng ngẫu nhiên) sao cho Bộ lọc đó phản ứng cực đại.
- Bức ảnh ảo sinh ra chính là hiện thân cho "Mẫu lý tưởng" mà Bộ lọc đó đang khát khao tìm kiếm.
- Đây là thuật toán **Gradient Ascent (Leo đồi Gradient)**.

Toán học của Gradient Ascent trên Pixel

Trong huấn luyện thông thường (Gradient Descent): Cập nhật Trọng số (Weights) để giảm thiểu Loss.

$$W_{new} = W_{old} - \alpha \cdot \nabla_W L(W) \quad (1)$$


Trong Trực quan hóa Bộ lọc (Gradient Ascent): Cố định Trọng số, **Cập nhật Pixel ảnh (X)** để tối đa hóa Kích hoạt của Bộ lọc (Activation A).

$$X_{new} = X_{old} + \alpha \cdot \nabla_X A(X) \quad (2)$$


Ta tính Đạo hàm của Đầu ra Bộ lọc theo Đầu vào Ảnh, sau đó cộng thêm đạo hàm đó vào Ảnh để làm nó rõ nét hơn.

Quần thể các Mẫu Đặc trưng lý tưởng

- Kết quả của Gradient Ascent là những họa tiết kỳ ảo giống như ảo giác (Psychedelic).
- Các lớp nông (Shallow): Học màu sắc, vân gỗ, sóng nước.
- Các lớp giữa (Middle): Học kết cấu phức tạp hơn (chấm bi, sọc vằn, mạng nhện).



- Đối với các khối ở cực sâu (như block5_conv1 của VGG16), các họa tiết bắt đầu mang hình thù của vật thể thực.
- Chẳng hạn, bộ lọc này tổng hợp nên họa tiết hình elip đan chéo, rất giống nan hoa xe đạp (Bicycles) hoặc vảy bò sát.



Hình 10.6: Họa tiết bộ lọc siêu sâu (Xe đạp / Vảy)

Kỹ thuật 3: Class Activation Map (CAM)

- **Mục tiêu:** Trả lời câu hỏi "Phần nào của bức ảnh đã khiến Mạng CNN đưa ra quyết định phân loại này?".
- Rất hữu ích cho **Phân tích lỗi (Error Analysis)** (Tại sao nhận diện sai?) và **Khám phá Y khoa** (Chỉ ra khối u nằm ở đâu trên ảnh X-Quang).
- Phương pháp SOTA (State-of-the-art) là **Grad-CAM** (Gradient-weighted Class Activation Mapping).

- 1 Tính Đạo hàm của xác suất Lớp dự đoán (Vd: African elephant y^c) theo toàn bộ Bản đồ đặc trưng (Feature Maps A^k) ở Lớp Tích chập **cuối cùng**.
- 2 Lấy Trung bình không gian (Global Average Pooling) của Đạo hàm này để ra Trọng số độ quan trọng α_k^c của Kênh k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{i,j}^k} \quad (3)$$

- 3 Nhân chập Trọng số với Feature Maps tương ứng, rồi bọc qua hàm ReLU (chỉ lấy phần dương - Positive influence):

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right) \quad (4)$$

Đầu vào bài toán Phân tích Lỗi


- Ta đưa bức ảnh chụp hai con Voi châu Phi và con cái của chúng vào mô hình VGG16.
- VGG16 dự đoán: Voi châu Phi (African elephant) với xác suất cực cao.
- Câu hỏi: Nó nhìn vào Voi mẹ hay Voi con để ra quyết định?



Hình 10.7: Ảnh Voi châu Phi đầu vào

Bản đồ Nhiệt (Heatmap) Grad-CAM

- Áp dụng công thức Grad-CAM ở lớp `block5_conv3` của VGG16.
- Kết quả là một mảng Numpy 2D. Điểm có giá trị càng cao (Vùng sáng) thì càng tác động lớn đến quyết định "Đây là con voi".



Hình 10.8: Bản đồ nhiệt Grad-CAM

Bản đồ Nhiệt Chồng chập (Superimposed Heatmap)

- Dùng OpenCV để chồng bản đồ nhiệt lên ảnh gốc, chuyển sang phổ màu JET.
- **Kết luận đột phá:** Vùng đỏ rực tập trung chính xác vào **Đôi tai** của Voi con. Tai là đặc điểm sinh học định danh duy nhất phân biệt Voi châu Phi và Voi Ấn Độ.
- Mạng VGG16 hoàn toàn không bị ngốc! Nó đã học đúng đặc điểm nhận dạng cốt lõi!



Hình 10.9: Bản đồ Grad-CAM hiển thị tai Voi con

- Mạng Tích chập **KHÔNG** phải là Hộp đen. Ta có thể "Nội soi" chúng dễ dàng.
- **Intermediate Activations:** Phân tích tính trừu tượng tăng dần của Feature Maps.
- **Filter Visualization (Gradient Ascent):** Đạo hàm ngược lên Pixel ảnh để tìm hiểu xem mỗi Bộ lọc yêu thích mẫu họa tiết (Pattern) nào nhất.
- **Grad-CAM (Bản đồ Kích hoạt Lớp):** Truy vết Đạo hàm của Lớp để xác định vùng Đóng góp lớn nhất, tạo thành công cụ đắc lực cho Phân tích lỗi và Diễn dịch mô hình.