

Học Sâu (Deep Learning)

Chương 16: Sinh văn bản & Kỹ nguyên AI Tạo sinh

Đại học Đông Á

July 23, 2026

Nội dung chương

1. 1. Kỹ nguyên AI Tạo sinh (Generative AI)
2. 2. Mô hình Ngôn ngữ Lớn (LLMs) & Chiến lược lấy mẫu
3. 3. Tinh chỉnh Mô hình Tỷ tham số với LoRA
4. 4. Đa phương thức (Multimodal) & Kỹ thuật Huấn luyện
5. 5. Tổng kết

Trí tuệ Nhân tạo Tạo sinh là gì?

- Khác biệt với AI Phân loại (Classification) dùng để nhận diện dữ liệu, **Generative AI** được thiết kế để **tạo ra nội dung hoàn toàn mới** (Văn bản, Hình ảnh, Âm thanh, Code).
- AI tạo sinh hoạt động bằng cách học các mẫu (patterns) và cấu trúc thống kê ẩn (Latent space) từ lượng dữ liệu khổng lồ của con người.
- Sau đó, nó thực hiện một phép "lấy mẫu" (Sampling) từ không gian tiềm ẩn đó để tạo ra sản phẩm.

Sự kết hợp giữa AI và Nghệ thuật


- AI không hề "cướp" đi sự sáng tạo, mà nó đóng vai trò như một chiếc bút vẽ vô hạn quyền năng (Augmented Intelligence).
- Midjourney, DALL-E, hay Stable Diffusion cho phép những người không có kỹ năng vẽ tay vẫn có thể tạo ra các tác phẩm nghệ thuật phức tạp chỉ bằng ngôn ngữ (Prompt engineering).



Hình 16.1: Hình ảnh tạo ra từ Midjourney bằng văn bản

Sự bùng nổ của Large Language Models (LLMs)

- Nhờ kiến trúc Transformer (Chương 15), khả năng mở rộng (Scale-up) của mô hình ngôn ngữ bùng nổ dữ dội.
- LLM sử dụng kiến trúc **Decoder-only** (Dự đoán từ tiếp theo tự hồi quy).
- Số lượng tham số (Parameters) tăng từ vài trăm triệu (ELMo, GPT-1) lên tới hàng trăm tỷ, nghìn tỷ (GPT-4, PaLM, LLaMA).



Hình 16.2: Sự gia tăng kích thước của LLM theo thời gian

Làm sao AI có tính "Sáng tạo"?

- Bản chất của LLM là xuất ra một mảng Xác suất (Probability Distribution) cho hàng chục nghìn từ ngữ tiếp theo.
- Nếu ta luôn chọn từ có xác suất cao nhất (Greedy Search), câu văn sẽ vô cùng rập khuôn, lặp đi lặp lại và nhàm chán (Giống như Autocomplete trên điện thoại).
- **Giải pháp:** Đưa sự **Ngẫu nhiên (Stochasticity)** vào việc chọn từ bằng các chiến lược Lấy mẫu (Sampling Strategies).

Kỹ thuật Nhiệt độ (Temperature Sampling)

- Nhiệt độ T là một siêu tham số (Hyperparameter) điều khiển mức độ "Sáng tạo" (Ngẫu nhiên) của văn bản sinh ra.
- Công thức Softmax điều chỉnh với T :


$$p_i = \frac{\exp(\text{logit}_i / T)}{\sum_j \exp(\text{logit}_j / T)}$$

- **Khi $T < 1$ (VD: 0.1):** Các từ có xác suất cao sẽ được phóng to (Trở nên bảo thủ, phù hợp cho viết Code, Toán).
- **Khi $T > 1$ (VD: 1.5):** Các xác suất bị san bằng, mô hình dám chọn những từ "lạ" (Trở nên sáng tạo, phù hợp cho viết Thơ, Truyện).

Kỹ thuật Top-K và Top-p (Nucleus Sampling)

Dù có Nhiệt độ, AI đôi lúc vẫn chọn phải những từ vô nghĩa nếu xác suất ban đầu quá thấp.

- **Top-K:** Lọc ra K từ có xác suất cao nhất (VD: 50 từ). Sau đó chỉ lấy mẫu ngẫu nhiên trong nhóm này.
- **Top-p (Nucleus):** Lọc ra một nhóm từ sao cho Tổng xác suất cộng dồn của chúng vừa chạm ngưỡng p (VD: 0.9). Cách này rất linh hoạt, số lượng từ được chọn sẽ tự động co giãn tùy ngữ cảnh.



Hình 16.3: Cơ chế chặn lọc của Top-K và Top-p


Vấn đề của Fine-Tuning LLM

- Huấn luyện lại (Fine-tune) toàn bộ một mô hình LLM 7 tỷ tham số (VD: LLaMA-7B) đòi hỏi lượng RAM GPU khổng lồ (vượt quá 100GB).
- Điều này là bất khả thi đối với các nhà nghiên cứu độc lập và sinh viên, những người chỉ có card đồ họa máy tính cá nhân (16GB - 24GB).
- **LoRA (Low-Rank Adaptation)** được Microsoft giới thiệu năm 2021 để giải quyết bài toán này.

Giải pháp Đại số Tuyến tính: LoRA (Low-Rank Adaptation)

- Đóng băng toàn bộ trọng số gốc W_0 của mô hình.
- Chỉ cập nhật một ma trận thay đổi nhỏ ΔW .
- **Mẫu chốt Toán học:** Phân rã ma trận khổng lồ ΔW ($d \times k$) thành tích của hai ma trận cực kỳ nhỏ A ($d \times r$) và B ($r \times k$).
- Số chiều Rank r thường rất nhỏ (VD: 4, 8, 16).

$$W_{\text{mới}} = W_0 + (A \times B)$$




Hình 16.4: Cơ cấu ma trận A và B của Lớp LoRA

Sự hiệu quả đáng kinh ngạc của LoRA

- Số lượng tham số cần Train giảm xuống cực kỳ khủng khiếp.
- VD: Ma trận gốc $10000 \times 10000 = 100,000,000$ tham số.
- Nếu dùng LoRA Rank $r = 8$: Ma trận A (10000×8) và B (8×10000) $\rightarrow$ Tổng cộng chỉ có 160,000 tham số (Giảm hơn 600 lần).
- Hiệu năng (Độ thông minh) của mô hình gần như không thua kém việc Fine-tune toàn bộ trọng số.


Total memory = parameters + gradients + optimizer state + forward pass



Hình 16.5: LoRA tiết kiệm tối đa VRAM GPU

Kỹ thuật huấn luyện Transformer: Learning Rate Warmup


- Khác với mạng CNN hay LSTM, mạng Transformer cực kỳ nhạy cảm ở giai đoạn đầu lúc khởi tạo ngẫu nhiên.
- Nếu dùng Tốc độ học (Learning Rate) quá lớn ngay từ đầu, gradient sẽ phát nổ.
- **Warmup:** Learning Rate bắt đầu ở 0, tăng tuyến tính dần dần trong vài nghìn bước đầu tiên (Warmup phase), sau đó mới giảm dần theo hàm Cosine.



Hình 16.6: Đồ thị Learning Rate Warmup Decay

Tiến hóa thành Mô hình Đa phương thức (Multimodal Transformer)

- Khả năng của LLM không chỉ giới hạn ở Văn bản (Text).
- Bằng cách kết hợp một Bộ nén hình ảnh (Vision Encoder - như ViT) nối vào mô hình Ngôn ngữ, ta có **Vision-Language Model (VLM)**.
- AI giờ đây không chỉ biết đọc chữ, mà còn biết "Nhìn" và thảo luận về bức ảnh bạn gửi.



Hình 16.7: Kiến trúc Vision-Language Model

Thực nghiệm với Mô hình Đa phương thức (Gemma/PaliGemma)

- Truyền một bức ảnh vào mô hình VLM (như PaliGemma).
- Đưa ra Prompt: "Hãy miêu tả chi tiết những gì bạn thấy trong bức ảnh này".
- Mô hình sử dụng Attention để ánh xạ sự chú ý từ các vùng trong ảnh sang các từ ngữ tương ứng, đưa ra một đoạn miêu tả cực kỳ chuẩn xác và giống con người.



Hình 16.8: AI tự động miêu tả hình ảnh bằng văn bản

- **Large Language Models (LLMs):** Sự trỗi dậy của mô hình siêu khổng lồ nhờ kiến trúc Transformer Decoder.
- **Chiến lược Lấy mẫu (Sampling):** Sử dụng Nhiệt độ (Temperature), Top-K, Top-p để cân bằng giữa sự logic và tính sáng tạo của AI.
- **LoRA (Low-Rank Adaptation):** Kỹ thuật phân rã ma trận thần thánh giúp Fine-tune mô hình tỷ tham số trên máy tính cá nhân.
- **Multimodal (Đa phương thức):** Bước tiến tiếp theo của AI, kết hợp Viễn cảnh (Vision) và Ngôn ngữ (Language) vào chung một không gian biểu diễn.