

Học Sâu (Deep Learning)

Chương 17: Trí tuệ Nhân tạo Sinh ảnh (Image Generation)


Đại học Đông Á

July 23, 2026

1. Không gian tiềm ẩn & Text-to-Image
2. Mạng Variational Autoencoders (VAEs)
3. Kỹ nguyên Diffusion Models
4. Stable Diffusion & Kỹ thuật nâng cao
5. Tổng kết

Khái quát về Sinh ảnh (Image Generation)


- Ý tưởng cốt lõi của việc sinh ảnh là phát triển một **Không gian tiềm ẩn (Latent Space)** với số chiều thấp.
- Bất kỳ điểm nào trong không gian này đều có thể được một bộ **Generator/Decoder** ánh xạ thành một bức ảnh hợp lệ.
- AI không hề sao chép, nó Lấy mẫu (Sample) một tọa độ mới hoàn toàn và sinh ra bức ảnh chưa từng tồn tại.



Hình 17.1: Sử dụng Không gian tiềm ẩn để lấy mẫu ảnh mới

Mô hình Text-to-Image (Văn bản thành Hình ảnh)


- Bằng cách ánh xạ không gian văn bản (Text embedding) vào cùng không gian tiềm ẩn của hình ảnh (Image Latent Space).
- Ta có thể sinh ảnh dựa trên sự điều hướng của ngôn ngữ tự nhiên. VD: *"Một con ngựa đạp xe trên mặt trăng"*.
- Dù AI chưa từng thấy bức ảnh nào như vậy, nó vẫn nội suy được từ các khái niệm rời rạc.



Hình 17.2: Sinh ảnh bằng điều hướng Ngôn ngữ

Bộ dữ liệu kinh điển: Oxford Flowers


- Trong chương này, chúng ta sẽ thực hành huấn luyện AI sinh ảnh trên bộ dữ liệu **Oxford Flowers 102**.
- Nó bao gồm hàng ngàn bức ảnh hoa với đủ màu sắc, hình dáng, là "chuột bạch" lý tưởng cho các mô hình sinh ảnh như VAE hay Diffusion.



Hình 17.3: Một số mẫu từ bộ dữ liệu Oxford Flower

Giới hạn của Autoencoder truyền thống


- Mạng Autoencoder gồm 2 phần: Encoder nén ảnh thành mã (code) và Decoder giải nén mã về lại ảnh ban đầu.
- Tuy nhiên, Không gian tiềm ẩn (Latent space) của nó bị **đứt gãy**. Nếu lấy một điểm ngẫu nhiên ở giữa không gian, Decoder sẽ nhả ra một bức ảnh rác vô nghĩa.



Hình 17.4: Autoencoder truyền thống

Sự đột phá của Variational Autoencoder (VAE)

- VAE (2013) không nén ảnh thành 1 điểm cứng nhắc. Nó nén ảnh thành một **Phân phối xác suất** (Phân phối chuẩn hình chuông).
- Thay vì xuất ra tọa độ z , Encoder xuất ra **Trung bình (Mean)** và **Phương sai (Variance)**.
- Không gian tiềm ẩn giờ đây liên tục và trơn tru. Bất kỳ điểm nào lấy mẫu (Sample) cũng sinh ra ảnh hợp lệ.




Hình 17.5: Cơ chế học Phân phối chuẩn của VAE

Toán học của VAE: KL Divergence Loss

- Hàm mất mát của VAE gồm 2 phần: Loss tái tạo (Reconstruction Loss) + KL Divergence Loss.
- **Kullback-Leibler (KL) Divergence:** Là thước đo Toán học ép Phân phối do Encoder sinh ra phải bám sát với Phân phối chuẩn $N(0, 1)$.
- Nhờ KL Loss, các không gian khái niệm không bị co cụm rải rác mà được gom lại thành một khối tụ quy tâm, giúp việc chuyển đổi diễn ra mượt mà.

Kết quả sinh ảnh từ VAE


- Khi ta di chuyển tuần tự qua các tọa độ 2D của Không gian VAE, hình ảnh sẽ biến đổi (Morphing) rất trơn tru.
- **Nhược điểm:** Ảnh sinh ra bởi VAE thường hay bị mờ (Blurry) do đặc tính của hàm MSE Loss lấy trung bình điểm ảnh.



Hình 17.6: Không gian nội suy ảnh của VAE

Mô hình Khuếch tán (Diffusion Models)


- Từ năm 2020, VAE và GAN đã bị lật đổ bởi **Diffusion**.
- **Forward:** Phá hủy ảnh bằng cách thêm nhiễu (Noise) dần dần cho đến khi chỉ còn nhiễu tĩnh.
- **Backward:** Huấn luyện mạng Nơ-ron (U-Net) học cách gỡ bỏ nhiễu từng bước một để khôi phục ảnh.



Hình 17.7: Tiến trình Forward và Backward của Diffusion

Lịch trình thêm nhiễu (Noise Schedule)


- Lượng nhiễu thêm vào ở mỗi bước t không được ngẫu nhiên mà tuân theo một Toán đồ học **Noise Schedule** (Linear, Cosine,...).
- Việc này giúp mô hình kiểm soát được "Mức độ tàn phá" của ảnh gốc để có thể đảo ngược chính xác.



Hình 17.8: Các phương pháp Lịch trình Nhạy nhiễu

Mạng U-Net trong Diffusion

- Mô hình đóng vai trò khử nhiễu (Denoising) chính là **Mạng U-Net**.
- Ban đầu là mạng chuyên dùng cho y tế, U-Net (Với các kết nối chéo Skip-Connections) cực kỳ xuất sắc trong việc phục hồi chi tiết ảnh đồng kích thước với đầu vào.



Hình 17.9: Sơ đồ kiến trúc U-Net kinh điển

Kết quả sinh ảnh hoa từ Diffusion

- So với VAE, Diffusion mất rất nhiều bước tính toán (Sampling steps) để tạo ra ảnh, khiến nó chạy chậm hơn.
- **Đổi lại:** Chất lượng hình ảnh cực kỳ sắc nét, giữ được chi tiết siêu nhỏ, khắc phục hoàn toàn điểm yếu hình ảnh bị mờ của VAE.



Hình 17.10: Hình ảnh hoa sắc nét sinh từ Diffusion

Ứng dụng: Nâng cao độ phân giải (Super Resolution)

- Thuật toán Diffusion cực kỳ giỏi trong việc điền vào các điểm ảnh bị khuyết.
- Ta có thể đưa cho nó một bức ảnh siêu mờ (Low-res), và yêu cầu nó khử nhiễu (Denoise) để tạo ra bản rõ nét gấp 4 lần (Super Resolution).



Low-resolution image
with artifacts



Crisp high-resolution image

Hình 17.11: Phục hồi ảnh bằng Siêu phân giải

Stable Diffusion (Latent Diffusion)

- Khử nhiễu trên không gian Pixel khổng lồ (Ví dụ ảnh 1024×1024) là rất nặng và lâu.
- **Stable Diffusion (SD)**: Chạy Diffusion trên Không gian tiềm ẩn (Ví dụ 64×64) của VAE!
- Giúp SD sinh ảnh siêu đẹp mà chỉ tốn vài giây trên máy tính cá nhân.



Hình 17.12: Bức ảnh sinh ra từ Stable Diffusion 3

Tác động của Số bước Khử nhiễu (Denoising Steps)

- Diffusion không sinh ảnh 1 lần, nó sinh qua N bước lặp.
- Nếu N quá nhỏ (VD: 5 bước), ảnh còn đọng lại nhiều hạt (Noise).
- Tăng N lên (20 - 50 bước) sẽ giúp các chi tiết hiện rõ và hoàn thiện bức ảnh, tuy nhiên đánh đổi bằng thời gian.



Hình 17.13: Sự thay đổi chi tiết theo số bước lặp

Sức mạnh của Negative Prompt (Lời nhắc tiêu cực)

- **Negative Prompt:** Kỹ thuật ép AI "tránh xa" những đặc điểm ta không mong muốn (Xấu, mờ, biến dạng, nhiều ngón tay...).
- Về Toán học, điều này đẩy Vector tiềm ẩn ra xa khỏi hướng của các Vector khái niệm xấu trong Latent Space, giúp ảnh ra hoàn hảo hơn.



Hình 17.14: So sánh khi có và không có Negative Prompt

Nội suy hình học trong Không gian tiềm ẩn

- Bằng cách tạo ra điểm đầu A và điểm cuối B trong Không gian tiềm ẩn, ta có thể tính toán các điểm nằm giữa chúng.
- Khi đưa các điểm nằm giữa này qua mô hình để sinh ảnh, ta được hiệu ứng **Morphing** (Biến hình) trơn tru từ cảnh A sang cảnh B .




Hình 17.15: Hiệu ứng chuyển cảnh trong Latent Space

Toán học Nội suy cầu (SLERP)

- Trong không gian nhiều chiều ($D \approx 4096$), nội suy tuyến tính đường thẳng (Linear) bị sai lệch hình học.
- Giải pháp Toán học là **Spherical Linear Interpolation (SLERP)**: Đi đường cong theo bề mặt hình cầu đa chiều.


$$SLERP(p_0, p_1, t) = \frac{\sin((1-t)\Omega)}{\sin(\Omega)} p_0 + \frac{\sin(t\Omega)}{\sin(\Omega)} p_1$$



Hình 17.16: Minh họa đường đi SLERP cong bám cầu

Góc độ Hình học của Cosine

- Tham số Ω trong công thức SLERP chính là góc giữa hai Vector p_0 và p_1 .
- Nó được tính qua **Cosine Similarity**:
$$\cos(\Omega) = \frac{p_0 \cdot p_1}{\|p_0\| \|p_1\|}.$$
- SLERP đảm bảo quá trình chuyển hóa tốc độ góc ổn định, giúp ảnh không bị vỡ vụn ở khúc giữa như thuật toán Tuyến tính thường làm.



Hình 17.17: Mối quan hệ hình học Cosine

Tổng kết Chương 17

- **VAE:** Cơ chế học phân phối xác suất hình chuông để tạo ra một không gian sinh ảnh liên tục nhờ hàm mất mát KL Divergence.
- **Diffusion Models:** Thay đổi cuộc chơi bằng quá trình Thêm nhiễu và dùng mạng U-Net Khử nhiễu, khắc phục hoàn toàn bệnh mờ ảnh của VAE.
- **Stable Diffusion:** Tối ưu hóa Diffusion bằng cách chạy trên Không gian tiềm ẩn thay vì Pixel thô, mở ra kỷ nguyên AI nghệ thuật trên PC.
- **Toán học không gian đa chiều:** Sự cần thiết của thuật toán Nội suy cầu SLERP và Cosine Similarity khi muốn điều hướng các vector không lồ.